

سوال ۱-۲) بسط تیلور تابع را حول w^* می نویسیم. فرض کنیم w^* نقطه ای است که gradient descent به آن رسیده است:

$$J(w) = J(w^*) + \underbrace{\nabla J(w^*)^T}_{=0} (w - w^*) + \frac{1}{2} (w - w^*)^T H (w - w^*)$$

حل فرض کنیم \tilde{w} همان w^* است که فقط یکی از درجه ها صفر نشده است. فرض کنیم درجه k صفر نشده:

$$w^* = \begin{bmatrix} w_1^* \\ \vdots \\ w_n^* \end{bmatrix} \rightarrow \tilde{w} = \begin{bmatrix} w_1^* \\ \vdots \\ 0 \\ \vdots \\ w_n^* \end{bmatrix} \leftarrow \text{درجه } k$$

اگر $J(\tilde{w})$ را حساب کنیم:

$$J(\tilde{w}) = J(w^*) + \frac{1}{2} (\tilde{w} - w^*)^T H (\tilde{w} - w^*)$$

$\tilde{w} - w^*$ برداری است که نقطه درجه k آن نامنظم و برابر w_k^* است. در نتیجه اگر H به صورت زیر باشد:

$$H = [h_1, \dots, h_n] \rightarrow H(\tilde{w} - w^*) = -w_k^* h_k \Rightarrow (\tilde{w} - w^*)^T (-w_k^* h_k)$$

$$= w_k^{*2} H_{kk} \Rightarrow J(\tilde{w}) = J(w^*) + H_{kk} w_k^{*2}$$

یعنی اگر w_k^* را حذف کنیم، تابع هزینه به اندازه $w_k^{*2} H_{kk}$ زیاد می شود. در نتیجه باید درجه ای را انتخاب کنیم که مقدار $w_k^{*2} H_{kk}$ کمترین باشد. توجه شود که فرض می کنیم local minimum به نقطه بهینه محلی رسیده است در نتیجه $H_{kk} > 0$ است یعنی هزینه بعد از حذف w_k^* افزایش یابد.

ب) اگر H همانی باشد، $H_{kk} = 1$ برای همه k ها در نتیجه خواهیم داشت:

$$J(\tilde{w}) = J(w^*) + w_k^{*2}$$

در نتیجه باید درجه ای را حذف کنیم که کمترین اندازه را دارد. برای این کار \tilde{w} را بخواهیم مثلاً k درجه حذف کنیم، k درجه ای که کوچکترین اندازه را دارد را حذف می کنیم.

$$X = \begin{bmatrix} x_1^T \\ \vdots \\ x_N^T \end{bmatrix}, \quad x_i \in \mathbb{R}^d$$

$$y_i = b^T x_i + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

(آ) سعی کنید تا از لای زینم، در صورت $\hat{y} = Xb$ خواهد بود. درستی؟

$$C = \|y - \hat{y}\|_2^2 = \|Xb - y\|_2^2 \Rightarrow \hat{b} = \underset{b}{\operatorname{argmin}} \|Xb - y\|_2^2$$

ی دانیم که جواب این مسئله از pseudo inverse ماتریس X بدست می آید:

$$\hat{b} = X^+ y$$

$$\hat{b} = (X^T X)^{-1} X^T y$$

حال چون X رتبه کامل است ($N > d$) درستی؟

دلیل محسوس پذیر بودن $X^T X$ این است که فضای سطر X و $X^T X$ برابر است و فضای سطر X هم دارای رتبه d است. چون $X^T X$ ماتریس $d \times d$ است، فضای سطر آن دارای d پایه است یعنی رتبه کامل است، معکوس پذیر باشد.

$$A^T = X (X^T X)^{-1} X^T$$

$$A = X (X^T X)^{-1} X^T \quad \text{ب) آید}$$

$$A^2 = \underbrace{X (X^T X)^{-1} X^T}_I X (X^T X)^{-1} X^T = X (X^T X)^{-1} X^T$$

درستی؟ $A^T = A$ و متقارن است.

درستی؟ $A^2 = A$ است، چون A متقارن است، می توان تجزیه به مقادیر ویژه انجام داد:

$$A = Q \Lambda Q^T \rightarrow A^2 = Q \Lambda^2 Q^T$$

درستی؟ مقادیر ویژه A^2 ، توان در مقادیر ویژه A هستند، اگر آن ها را λ_i نشان دهیم:

$$\lambda_i = \lambda_i^2 \rightarrow \lambda_i (\lambda_i - 1) = 0 \rightarrow \begin{cases} \lambda_i = 0 \\ \lambda_i = 1 \end{cases}$$

$A = X(X^T X)^{-1} X^T$ یک ماتریس $N \times N$ است. ثابت می‌کنیم فضای ستونی آن با فضای ستونی X برابر است. هر $x \neq 0$ را اگر در نظر بگیریم که $X^T x = 0$ باشد؛

$$Ax = X(X^T X)^{-1} X^T x = 0 \longrightarrow \text{Null space of } X^T \subseteq \text{Null space of } A$$

برعکس هر x ای که $Ax = 0$ باشد، $x \neq 0$ داریم؛

$$Ax = 0 \longrightarrow X(X^T X)^{-1} X^T x = 0$$

چون $(X^T X)^{-1}$ رتبه کامل است هیچ $y \neq 0$ ای موجود نیست که $(X^T X)^{-1} y = 0$ باشد. همچنین چون X رتبه کامل ستونی است، هیچ $y \neq 0$ ای موجود نیست که $Xy = 0$ باشد. در نتیجه حتماً $X^T x = 0$ است.

در نتیجه $N(A) \subseteq N(X^T)$ ، از این در نتیجه می‌گیریم فضای ستونی X با فضای ستونی A برابر

است. در نتیجه rank ماتریس A برابر d است. در نتیجه A ، d مقدار ویژه 1 و $N-d$ مقدار ویژه 0 برابر با 0 دارد. ماتریس $A-I$ نیز متقارن است و d مقدار ویژه 0 و $N-d$ مقدار ویژه 1- دارد.

$$E \left[\frac{1}{N} \| (I-A)y \|_2^2 \right] = \frac{1}{N} E \left[\| (I-A)y \|_2^2 \right] \quad \text{درستی}$$

$$\Rightarrow \frac{1}{N} E \left[\| \Phi^T A^T y \|_2^2 \right] = \frac{1}{N} E \left[\left\| \sum_{i=1}^{N-d} \phi_i \phi_i^T y \right\|_2^2 \right] \quad \text{لر تجزیه به سیمایر دیفره را برای } I-A \text{ انجام دهیم:}$$

چون Φ ماتریس unitary است، دیتون های آن متعامد یکدیگر هستند، داریم:

$$\Rightarrow \frac{1}{N} E \left[\sum_{i=1}^{N-d} (\phi_i^T y)^2 \right] = \frac{1}{N} E \left[\sum_{i=1}^{N-d} (y^T \phi_i)^2 \right]$$

ϕ_i بردار ویژه متعامد مقدار ویژه 1 در $I-A$ است یعنی:

$$(I-A)\phi_i = \phi_i \rightarrow y^T \phi_i = \phi_i^T y = \phi_i^T (I-A)y = \phi_i^T (y - Ay) = \phi_i^T \varepsilon$$

$$\text{where } \varepsilon = \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \Rightarrow E[(\phi_i^T \varepsilon)^2] = E\left[\left(\sum_j \phi_{ij} \varepsilon_j\right)^2\right] = \sum_j \phi_{ij}^2 E[\varepsilon_j^2] = \sum_j \phi_{ij}^2 \delta^2$$

$$= \delta^2 \sum_j \phi_{ij}^2 = \delta^2$$

درستی

$$\frac{1}{N} E \left[\| (I-A)y \|_2^2 \right] = \frac{1}{N} (N-d) \delta^2 = \frac{N-d}{N} \delta^2$$

(ج) با توجه به رابطه ای که بالا بدست آمد، در صورت رابطه $N-d$ موجود است، اگر N به نزدیک باشد، خطای training میل کم می شود. در نتیجه باید تعداد example ها بیشتر از تعداد feature ها باشد که

overfitting رخ نهد.

$$J = \left(y_d - \sum_{k=1}^n s_k w_k x_k \right)^2, \quad s_k \sim N(1, \delta^2)$$

سوال 4 - 1

$$\frac{\partial J}{\partial w_j} = 2 s_j x_j \left(\sum_{k=1}^n s_k w_k x_k - y_d \right) = -2 s_j x_j y_d + 2 s_j x_j \sum_{k=1}^n s_k w_k x_k$$

$$= -2 s_j x_j y_d + 2 s_j^2 x_j^2 w_j + 2 s_j x_j \sum_{\substack{k=1 \\ k \neq j}}^n s_k w_k x_k$$

$$\Rightarrow E \left[\frac{\partial J}{\partial w_j} \right] = -2 x_j y_d + 2 x_j^2 w_j E[s_j^2] + 2 x_j \sum_{\substack{k=1 \\ k \neq j}}^n E[s_j s_k] w_k x_k$$

چون s_j و s_k مستقل فرض می‌شوند، $E[s_j] E[s_k] = E[s_j s_k] = 1$ ، همچنین $E[s_j^2] = \delta^2 + 1$

$$E \left[\frac{\partial J}{\partial w_j} \right] = -2 x_j y_d + 2 x_j^2 w_j \delta^2 + 2 x_j \sum_{\substack{k=1 \\ k \neq j}}^n w_k x_k + 2 x_j^2 w_j$$

در نتیجه،

با افزودن تابع هزینه بدون dropout، محاسبه کنیم،

$$\begin{aligned} \tilde{J} &= \left(y_d - \sum_{k=1}^n w_k x_k \right)^2 \Rightarrow \frac{\partial \tilde{J}}{\partial w_j} = 2 x_j \left(\sum_{k=1}^n w_k x_k - y_d \right) = -2 x_j y_d + 2 x_j \sum_{k=1}^n w_k x_k \\ &= -2 x_j y_d + 2 x_j^2 w_j + 2 x_j \sum_{\substack{k=1 \\ k \neq j}}^n w_k x_k \end{aligned}$$

$$\frac{\partial J}{\partial w_j} = \frac{\partial \tilde{J}}{\partial w_j} + 2 x_j^2 \delta^2 w_j \longrightarrow J = \tilde{J} + \sum_{j=1}^n 2 x_j^2 \delta^2 w_j^2$$

در نتیجه،

مشاهده می‌شود که یک عبارت به نرم $\sum w_k^2$ به تابع هزینه اضافه شده است، این مانند یک regularization (L2) عمل می‌کند و باعث جلوگیری از overfitting می‌شود.

$$J = w^T H w, \quad H = Q \Lambda Q^T$$

$$\nabla J = 2Hw \rightarrow w^t = w^{t-1} - \varepsilon \nabla J(w^{t-1}) \Rightarrow w^t = w^{t-1} - \varepsilon 2Hw^{t-1} \quad (1)$$

$$\Rightarrow w^t = w^{t-1} - 2\varepsilon Hw^{t-1}$$

$$w^t = (I - 2\varepsilon H) w^{t-1} \rightarrow w^1 = (I - 2\varepsilon H) w^0 \rightarrow w^t = (I - 2\varepsilon H)^t w^0 \quad (ب)$$

(ج) جاتوه به اینله H متعارف است، $I - 2\varepsilon H$ نیز متعارف است، و اگر مقادیر ویژه ماتریس H ، چه

λ_i ؟ باشند، مقادیر ویژه $I - 2\varepsilon H$ برابر $1 - 2\varepsilon \lambda_i$ هستند. اگر A یک ماتریس متعارف باشد که نرم

$A = Q \Lambda Q^T$ نرمه باشیم، $A^n = Q \Lambda^n Q^T$ است. حال اگر به جای A ماتریس A انوار کتاز I

دانه باشند، A^n به یک ماتریس همرا می شود. در نتیجه شرط همرا با این است که $|1 - 2\varepsilon \lambda_i| \leq 1$

باشد.

(د) الگوریتم نیوتن به مرتبه 2 را حساب می کند، بر اساس آن فقط بهری را انتخاب می کند.

$$J(w) = J(w^{t-1}) + \nabla J(w^{t-1})^T (w - w^{t-1}) + \frac{1}{2} (w - w^{t-1})^T \tilde{H} (w - w^{t-1})$$

$$\nabla J(w) = \nabla J(w^{t-1}) + \tilde{H} (w - w^{t-1}) = 0 \rightarrow \tilde{H} w - \tilde{H} w^{t-1} = -\nabla J(w^{t-1})$$

$$\Rightarrow \tilde{H} w - \tilde{H} w^{t-1} = -\nabla J(w^{t-1}) \rightarrow w = w^{t-1} - \tilde{H}^{-1} \nabla J(w^{t-1})$$

که \tilde{H} ماتریس هسین J است. جاتوه به تابع هزینه جالا،

$$\nabla J(w^{t-1}) = 2Hw^{t-1}, \quad \tilde{H} = 2H$$

$$w^t = w^{t-1} - \tilde{H}^{-1} \nabla J(w^{t-1}) = w^{t-1} - \frac{1}{2H} 2Hw^{t-1} = w^{t-1} - w^{t-1} = 0 !$$

در نتیجه در الگوریتم نیوتن خواهیم داشت:

$$w^1 = w^0 - w^0 = 0$$

از آن نقطه دلخواه شروع کنیم:

در نتیجه الگوریتم نیوتن در یک گام جواب مسئله را پیدا می کند. جاتوه به اینله تابع هزینه یک تابع quadratic است. به سبب مرتبه 2 تابع همان خود تابع است در نتیجه الگوریتم نیوتن به سرعت تحلیلی در یک گام، منبسم را پیدا می کند (فرض بر این است که تابع convex باشد یعنی $H \succ 0$).

(ه) الگوریتم نیوتن نیازمند کالک ماتریس Hessian، محوس کردن آن دارد که محوس گرفتن از ماتریس از $O(n^3)$ است. اگر ماتریس $n \times n$ باشد. در نتیجه هزینه محاسباتی را در صورتی که n بزرگ باشد، بسیار جالا می برد.

سوال 3- (ا)

$$Y = X\beta + \varepsilon$$

تقریب از Y به صورت $\hat{Y} = X\hat{\beta}$ است. در نتیجه اگر بخواهیم خطا را کم کنیم:

$$\hat{\beta} = \underset{\beta}{\operatorname{argmin}} \|Y - \hat{Y}\|_2^2 = \underset{\beta}{\operatorname{argmin}} \|X\beta - Y\|_2^2$$

بافتض اینکه X ، رتبه کامل نسبی باشد (نه رتبه صافی نه تعداد نمونه‌ها بسیار بیشتر از feature ها باشد همین است) خواهیم داشت:

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

(ب)

$$J = \|X\beta - Y\|_2^2 + \lambda \|\beta\|_2^2$$

این عبارت را می‌توان به صورت زیر نیز نوشت:

$$J = \left\| \begin{bmatrix} X \\ \sqrt{\lambda} I \end{bmatrix} \beta - \begin{bmatrix} Y \\ 0 \end{bmatrix} \right\|_2^2$$

با استفاده از حداقل مربعات، جواب بهینه برای β برابر خواهد بود با:

$$\hat{\beta} = \left(\begin{bmatrix} X^T & \sqrt{\lambda} I \end{bmatrix} \begin{bmatrix} X \\ \sqrt{\lambda} I \end{bmatrix} \right)^{-1} \begin{bmatrix} X^T & \sqrt{\lambda} I \end{bmatrix} \begin{bmatrix} Y \\ 0 \end{bmatrix} = (X^T X + \lambda I)^{-1} X^T Y$$

سوال 3-3 >

باتوجه به بخش ب) اگر $J = \|X\beta - y\|_2^2 + \lambda \|\beta\|_2^2$ باشد، می توان

آن را به صورت زیر نوشت:

$$J = \left\| \underbrace{\begin{bmatrix} X \\ \sqrt{\lambda} I \end{bmatrix}}_{\tilde{X}} \beta - \underbrace{\begin{bmatrix} y \\ 0 \end{bmatrix}}_{\tilde{y}} \right\|_2^2 = \|\tilde{X}\beta - \tilde{y}\|_2^2$$

باتوجه به این فرم می توان در نظر گرفت

که \tilde{X} همان ماتریس داده ها است که تعدادی داده به آن اضافه شده، \tilde{y} هم بردار label ها است که تعدادی داده به آن اضافه شده است.

داده های اضافه شده در \tilde{X} به فرم $\sqrt{\lambda} e_i$ هستند که e_i نشان نام ماتریس همانی است. label متناظر آن ها هم 0 می باشد. در نتیجه اگر

تابع هزینه ما به فرم رو به رو باشد، می توان گفت که هم مثل این است که تعدادی

داده اضافه شده، $\lambda_2 \|\beta\|_1$ نیز نشان دهنده L_1 regularization است.

$$L(\beta, \lambda_1, \lambda_2) = \|y - X\beta\|_2^2 + \lambda_1 \|\beta\|_2^2 + \lambda_2 \|\beta\|_1$$

سوال 6- الف) ترم $\|W\|_F^2$ موجود که regularization است، باعث می‌شود که مدل با overfit
 نکند. ترم $\|h_1 - h_2\|_2^2$ نیز سعی می‌کند که خاصه امکان خرابی‌ها نباشند. در واقع تبدیل $\tanh(Wx+b)$
 یک تبدیل غیرخطی است که x را به h ها map می‌کند و درست داریم در فضایی که x ها به آن map
 می‌شوند، خاصه امکان بهم نزدیک باشند. این network، تبدیل را یاد می‌گیرد. در واقع زیر فضای h را پیدا
 می‌کند. از این کاری‌ها برای فشرده سازی استفاده کرد. در واقع در $x \in \mathbb{R}^n$ است، خرابی $h \in \mathbb{R}^m$
 اگر $n \gg m$ باشد، این مدل عمل فشرده سازی را انجام می‌دهد.

$$x_1, x_2 \in \mathbb{R}^k \quad h_1 = \tanh(Wx_1 + b) \quad , \quad h_2 = \tanh(Wx_2 + b) \quad (ب)$$

$$J = \|h_1 - h_2\|_2^2 + \|W\|_F^2$$

$$\frac{\partial J}{\partial b} = \frac{\partial \|h_1 - h_2\|_2^2}{\partial b} = \frac{\partial \|h_1 - h_2\|_2^2}{\partial (h_1 - h_2)} \cdot \frac{\partial (h_1 - h_2)}{\partial b} = 2(h_1 - h_2) \frac{\partial (h_1 - h_2)}{\partial b}$$

$$\frac{\partial (h_1 - h_2)}{\partial b} = \frac{\partial h_1}{\partial b} - \frac{\partial h_2}{\partial b} \Rightarrow \frac{\partial h_1}{\partial b} = \frac{\partial \tanh(Wx_1 + b)}{\partial b} = \frac{\partial \tanh(Wx_1 + b)}{\partial (Wx_1 + b)} \cdot \frac{\partial Wx_1 + b}{\partial b}$$

$$\text{diag}(\tanh'(Wx_1 + b)) \quad I$$

$$\Rightarrow \frac{\partial (h_1 - h_2)}{\partial b} = 0 \tanh'(Wx_1 + b) - 0 \tanh'(Wx_2 + b)$$

$$\Rightarrow \frac{\partial J}{\partial b} = 2(h_1 - h_2)^T [0 \tanh'(Wx_1 + b) - 0 \tanh'(Wx_2 + b)]$$

$$\frac{\partial J}{\partial W} = \frac{\partial \|h_1 - h_2\|_2^2}{\partial W} + \underbrace{\frac{\partial \|W\|_F^2}{\partial W}}_{2W} \Rightarrow \frac{\partial \|h_1 - h_2\|_2^2}{\partial W} = \underbrace{\frac{\partial \|h_1 - h_2\|_2^2}{\partial (h_1 - h_2)}}_{2(h_1 - h_2)^T} \cdot \frac{\partial (h_1 - h_2)}{\partial W}$$

$$\Rightarrow 2(h_1 - h_2)^T \cdot \frac{\partial h_1}{\partial W} - 2(h_1 - h_2)^T \cdot \frac{\partial h_2}{\partial W}$$

$$\Rightarrow 2(h_1 - h_2)^T 0 \tanh'(Wx_1 + b) \cdot \frac{\partial (Wx_1 + b)}{\partial W} - 2(h_1 - h_2)^T 0 \tanh'(Wx_2 + b) \cdot \frac{\partial (Wx_2 + b)}{\partial W}$$

$$\Rightarrow \left(\frac{\partial \|h_1 - h_2\|_2^2}{\partial W} \right)_{ij} = s'_i x_j - s''_i x_j \quad \text{where} \begin{cases} s'_i = [2(h_1 - h_2)^T 0 \tanh'(Wx_1 + b)]_i \\ s''_i = [2(h_1 - h_2)^T 0 \tanh'(Wx_2 + b)]_i \end{cases}$$

$$\Rightarrow \frac{\partial \|h_1 - h_2\|_2^2}{\partial W} = (s')^T x^T - (s'')^T x^T \quad \text{where} \begin{cases} s' = 2(h_1 - h_2)^T 0 \tanh'(Wx_1 + b) \\ s'' = 2(h_1 - h_2)^T 0 \tanh'(Wx_2 + b) \end{cases}$$

$$= \left([2(h_1 - h_2)^T 0 \tanh'(Wx_1 + b)]^T - [2(h_1 - h_2)^T 0 \tanh'(Wx_2 + b)]^T \right) x^T$$

الوقت اگت در صورت زيدي شود: (فرق اينم batch size برابر K باشه)

$$b^t = b^{t-1} - \frac{\xi^t}{K} \sum_{i=1}^K \frac{\partial \|h_1^i - h_2^i\|_2^2}{\partial b}$$

$$W^t = W^{t-1} - \frac{\xi^t}{K} \sum_{i=1}^K \frac{\partial \|h_1^i - h_2^i\|_2^2}{\partial W}$$